PROYECTO 2 · UNIDAD DE APLICACIÓN

Clustering con Machine Learning y Aplicación Web

Inteligencia Artificial · Sexto Semestre · Ingeniería en Sistemas de Información

12.5	15 nov	≤ 3
PUNTOS	FECHA MÁXIMA	ESTUDIANTES / GRUPO

DATOS GENERALES

Asignatura	Inteligencia Artificial — Sexto Semestre, Ingeniería en Sistemas de Información
Modalidad	Grupos de hasta 3 estudiantes
Valor	12.5 puntos
Fecha máxima de entrega	Domingo 15 de noviembre de 2026
Entregables	Notebook (.ipynb) + Informe de la aplicación (PDF) + código de la app web
Sustentación	Breve demo en vivo en clase (5–10 min por grupo), fecha a confirmar cerca del 15 de noviembre

DESCRIPCIÓN Y OBJETIVO

Cada grupo seleccionará un dataset tabular de Kaggle adecuado para un problema de agrupamiento (clustering) y desarrollará un proyecto completo de machine learning no supervisado: desde la exploración de los datos hasta la construcción, comparación e interpretación de modelos de clustering, y su puesta en producción mediante una aplicación web que asigne nuevos registros al segmento que les corresponde.

El objetivo es que el estudiante demuestre dominio del ciclo completo de un proyecto de ML no supervisado — preparación y escalado de datos, reducción de dimensionalidad con PCA, construcción y comparación de K-Means y DBSCAN, selección justificada de hiperparámetros, evaluación sin etiquetas, interpretación de los segmentos en términos del problema, y despliegue del modelo en una interfaz usable— documentando cada decisión tomada en el camino, no solo el resultado final.

REQUISITOS DEL DATASET

- Debe provenir de Kaggle (kaggle.com/datasets) y estar disponible públicamente.
- El problema debe ser de agrupamiento: el dataset describe entidades (clientes, productos, países, estudiantes, transacciones, etc.) que se quieren segmentar en grupos con características similares, sin una variable objetivo para entrenar.

- Si el dataset trae una columna de etiqueta o clase, se excluye por completo: no entra al modelo ni se usa en el análisis.
- Debe ser tabular, con al menos 5 variables numéricas (continuas o discretas, no binarias) útiles para el agrupamiento. Las variables binarias 0/1 no entran al modelo, pero pueden usarse para interpretar los perfiles; las variables categóricas de texto se excluyen del análisis. No se aceptan imágenes, texto libre ni datasets triviales de 2–3 variables, como “Mall Customers”.
- Se recomienda un tamaño razonable (cientos a pocos miles de filas) para que el entrenamiento —en especial DBSCAN— y la app corran cómodamente en un equipo local.
- Cada grupo debe elegir un dataset distinto, diferente a los usados en los talleres de clase — el docente validará la elección antes de que el grupo avance con el desarrollo.
- Ejemplos de dominios válidos: segmentación de clientes (por ejemplo, análisis RFM de comercio electrónico o uso de tarjetas de crédito), perfiles socioeconómicos de países o cantones, patrones de consumo energético, perfiles de estudiantes, productos por composición química o nutricional, uso de servicios de telecomunicaciones, entre otros.

ALCANCE TÉCNICO DEL TRABAJO

El notebook debe documentar, en orden, todo el proceso de generación de los modelos:

1. **Contexto y pregunta de negocio:** qué se quiere segmentar, por qué importa y qué decisión podría tomarse a partir de los grupos encontrados.
2. **Análisis exploratorio de datos (EDA):** estructura del dataset, tipos de variable, valores faltantes, distribuciones, correlaciones y valores atípicos (y cómo podrían afectar a K-Means), con al menos 3 visualizaciones relevantes.
3. **Preparación de datos:** limpieza, imputación de valores faltantes, selección de las variables numéricas que entran al clustering (los identificadores, las variables binarias y las categóricas se excluyen de X; las binarias pueden usarse después para interpretar los perfiles) y escalado obligatorio con StandardScaler, justificando cada decisión.
4. **Reducción de dimensionalidad con PCA:** varianza explicada por componente y proyección en 2D para visualizar los clusters. Si se decide entrenar los modelos sobre las componentes principales en lugar de las variables originales, se debe justificar.
5. **Modelado con K-Means y DBSCAN (ambos obligatorios):** para K-Means, elegir K probando de K = 2 a 9 con el método del codo (inercia) y el coeficiente de Silhouette; para DBSCAN, fijar min_samples con la regla práctica vista en clase (MinPts ≥ D + 1; se sugiere 2·D, con D = número de variables) y elegir eps con el k-dist graph, reportando el número de clusters obtenidos y el porcentaje de puntos clasificados como ruido.
6. **Evaluación y comparación:** coeficiente de Silhouette de ambos modelos (en DBSCAN, calculado sin los puntos de ruido −1) y porcentaje de ruido de DBSCAN, visualización de ambos resultados en el mapa PCA, tamaño de cada cluster y análisis de cuál modelo produce una segmentación más útil y por qué.
7. **Interpretación de los segmentos:** perfil de cada cluster del modelo final (promedio de las variables en su escala original con groupby().mean(); en las binarias, ese promedio es la proporción de 1 en el cluster), un nombre descriptivo para cada segmento (por ejemplo, “clientes frecuentes de alto gasto”) y al menos una recomendación o acción concreta por segmento.
8. **Entrenamiento final y exportación:** entrenar el modelo elegido con el 100% de los datos (en clustering no hay división train/test) y exportar con joblib el Pipeline completo (StandardScaler + PCA si se usa + modelo) junto con los nombres de los segmentos. Si el modelo final es DBSCAN, que no tiene predict(), los registros nuevos se

asignan con la regla vista en clase: buscar con NearestNeighbors(n_neighbors=1) el punto core más cercano (components_); si está a una distancia ≤ eps toma su cluster, y si no, es ruido (−1).

Todo el código debe estar comentado y el notebook debe ser reproducible de principio a fin (ejecutar todas las celdas en orden sin errores).

APLICACIÓN WEB

- Debe implementar el modelo final para que un usuario ingrese los datos de un registro nuevo (formulario o carga de un registro) y reciba en tiempo real el cluster al que pertenece.
- El registro ingresado debe pasar por exactamente el mismo preprocesamiento que los datos de entrenamiento (mismo escalador y, si aplica, la misma transformación PCA), cargado desde los archivos exportados.
- Puede correr en local (no es necesario desplegarla en la nube ni contratar hosting); basta con que el grupo la ejecute y la muestre funcionando en su propio equipo.
- Framework libre: Streamlit, Flask, Gradio, Dash u otro framework de Python para aplicaciones web, siempre que corra localmente y permita hacer una asignación interactiva.
- Debe incluir, como mínimo: una interfaz para ingresar las variables de entrada (en su escala original), un botón o acción que ejecute la asignación, y una visualización clara del resultado: número y nombre del segmento, su perfil o recomendación, y un gráfico 2D (PCA) con los datos del dataset coloreados por cluster y el registro nuevo resaltado. Si el modelo es DBSCAN, la app debe indicar cuando el registro se considera ruido o atípico.
- El código de la app (incluyendo el pipeline exportado, los datos necesarios para el gráfico y las instrucciones para ejecutarla) se entrega junto con el notebook.

ENTREGABLES Y SUSTENTACIÓN

1. **Notebook (.ipynb):** con todo el proceso descrito en "Alcance técnico", código comentado y reproducible.
2. **Informe de la aplicación** (PDF, máximo ~5 páginas): describe los segmentos encontrados, la arquitectura de la app, cómo integra el modelo y el preprocesamiento, capturas de pantalla del funcionamiento, instrucciones de instalación/ejecución local y las limitaciones conocidas.
3. **Código fuente de la aplicación web** (repositorio o carpeta comprimida), incluyendo el pipeline exportado y un archivo de dependencias (requirements.txt o equivalente).
4. **Sustentación en clase:** cada grupo presenta una demo en vivo de la app (5–10 minutos), asignando al menos dos registros que caigan en segmentos distintos y explicando brevemente las decisiones de modelado y la interpretación de los clusters. Fecha a confirmar, cercana al 15 de noviembre.

> **Fecha máxima de entrega de los archivos**
> Domingo 15 de noviembre de 2026

RÚBRICA DE EVALUACIÓN (12.5 PUNTOS)

Criterio	Puntos	Descripción
1. EDA, preparación de datos y PCA	2.0	Exploración completa (distribuciones, correlaciones, valores faltantes/atípicos), limpieza, selección de variables numéricas y escalado con StandardScaler adecuados y justificados; PCA aplicado e interpretado correctamente (varianza explicada y loadings).
2. Modelado y selección de hiperparámetros	2.5	K-Means y DBSCAN implementados correctamente dentro de un Pipeline; K elegido con codo y Silhouette; min_samples justificado con la regla práctica y eps elegido con el k-dist graph.
3. Evaluación, comparación e interpretación de clusters	2.5	Uso e interpretación correctos de inercia, Silhouette (sin ruido en DBSCAN) y % de ruido, comparación razonada de ambos modelos, selección justificada del modelo final, y perfiles y nombres de segmentos coherentes con los datos y útiles para el problema.
4. Aplicación web funcional	2.5	La app corre localmente sin errores, aplica el mismo preprocesamiento del entrenamiento, asigna correctamente registros nuevos a un cluster (o ruido en DBSCAN) y muestra el segmento, su perfil y el gráfico 2D de forma clara.
5. Documentación del notebook	1.5	Código comentado, notebook reproducible de inicio a fin, narrativa clara que explica cada decisión tomada en el proceso.
6. Informe de la app y sustentación	1.5	Informe claro y completo; sustentación en clase demuestra comprensión del trabajo por todos los integrantes del grupo.
Total	**12.5**	

Nota sobre la sustentación

En la sustentación se puede preguntar individualmente a cada integrante sobre cualquier parte del proyecto.

Una participación desigual o que no pueda explicar su parte puede afectar la calificación individual dentro del grupo.